Clasificación de enfermedades foliares del café y evaluación de su generalización ante cambio de dominio

Cristobal Rodriguez Rojas · Juan Esteban Villada · Cristian David Cabezas Jimenez — Redes Neuronales y Aprendizaje Profundo, Universidad EAFIT, noviembre de 2026

1. Problema y objetivos

La roya del café (*Hemileia vastatrix*) y otras enfermedades foliares reducen la productividad del cultivo; su diagnóstico visual depende de expertos. Las redes convolucionales pueden aprender estos patrones de textura y color, pero los datasets públicos se capturan en condiciones controladas, por lo que es incierto si un modelo entrenado así funciona en campo. **Objetivo general:** desarrollar y evaluar un modelo de Deep Learning que clasifique enfermedades y plagas en hojas de café y medir cuantitativamente su generalización a datos de otra región, variedad y condición de captura. **Objetivos específicos:** (1) construir un pipeline de preprocesamiento y aumento con partición estratificada sin fuga de información; (2) entrenar y comparar una CNN desde cero, EfficientNet-B0 y ViT-Tiny con accuracy, F1-macro y costo computacional; (3) evaluar el mejor modelo en un dataset externo, cuantificar la caída de rendimiento y explicarla con Grad-CAM.

2. Datos y preprocesamiento

BRACOL (Krohling et al., 2019): 1747 fotos de hojas de café arábica (Brasil), desprendidas y sobre fondo blanco, etiquetadas con su estrés predominante. Se descartan 62 «indeterminadas» y quedan 1685 en 5 clases: sana 272, minador 387, roya 531, phoma 348, cercospora 147 (desbalance 3,6×; el 18,7 % tiene varios estreses). Partición estratificada 70/15/15 con semilla fija: 1179/253/253 imágenes. **RoCoLe** (Parraga-Alava et al., 2019), usado *solo* como conjunto externo: 1560 fotos de café robusta (Ecuador) tomadas en la planta, en campo: 791 sanas, 602 con roya (niveles 1–4) y 167 con arañita roja, una plaga ausente en BRACOL. El EDA cuantificó el cambio de dominio: el brillo medio baja de 0,62 a 0,41 y la fracción de fondo blanco de 30 % a 1 %; además las fotos de RoCoLe traen orientación EXIF (se corrige). **Preprocesamiento:** *letterbox* a 256×256 (conserva la geometría de las lesiones; relleno con la media de ImageNet), aumento solo en entrenamiento (recorte aleatorio 0,7–1, volteos, rotaciones de 90°, ColorJitter ±30 %), redimensión a 224 px y normalización con μ/σ de ImageNet. Con las máscaras de segmentación de RoCoLe se crearon tres versiones de cada foto externa: *raw*, *crop* (recorte a la hoja) y *mask* (fondo blanco), para aislar el efecto del fondo.

3. Modelos y entrenamiento

Se comparan (i) una **CNN base** desde cero (4 bloques [Conv3×3-BN-ReLU]×2 + MaxPool, GAP, FC; 1.17 M parámetros); (ii) **EfficientNet-B0** (Tan y Le, 2019; 16 bloques MBConv con convolución *depthwise* y Squeeze-Excitation; 4.01 M) y (iii) **ViT-Tiny/16** (Dosovitskiy et al., 2021; 196 parches, 12 bloques de *self-attention*; 5.53 M), ambos preentrenados en ImageNet y con la cabeza reemplazada por 5 salidas con dropout (única modificación; *fine-tuning* completo). Entrenamiento: AdamW, LR 1e-3 / 3e-4 / 1e-4 (CNN / EffNet / ViT), *warmup* de 2 épocas + coseno, batch 32, entropía cruzada ponderada por clase (pesos $N/(K \cdot n_c)$ de train) con *label smoothing* 0,1 y *early stopping* por F1-macro de validación (máx. 40/25 épocas). Ablación: EfficientNet-B0 solo con volteos. Equipo: CPU Intel Core i5-1155G7 (4 núcleos), sin GPU, 21 GB de RAM, PyTorch 2.15.0 y timm.

4. Resultados

Modelo	Accuracy	F1-macro	Mejor ép.	Parám.	Entrenam.	ms/img CPU
CNN base (desde cero)	84,2 %	80,8 %	19/29	1.17 M	105 min	67
EfficientNet-B0	88,1 %	86,4 %	19/25	4.01 M	89 min	53
ViT-Tiny/16	87,4 %	84,3 %	18/25	5.53 M	53 min	45
EfficientNet-B0 sin aumento	88,1 %	85,1 %	22/25	4.01 M	76 min	41

Tabla 1. BRACOL test (n = 253). El mejor modelo según F1 de validación es ViT-Tiny/16. Esgario et al. (2020) reportan 95,24 % de accuracy en este dataset con ResNet-50 multitarea (partición distinta).

Los modelos preentrenados alcanzan 87–88 % de accuracy y superan a la CNN desde cero en 3,4–5,5 puntos de F1-macro. ViT-Tiny fue seleccionado por tener el mayor F1 de validación (0,935); en test EfficientNet-B0 queda 1–2 puntos arriba, una diferencia de 3–5 imágenes de 253 que no consideramos significativa. Distinguir sana de enferma es trivial en este dominio (AUROC 1,0, recall de sanas 100 %): todos los errores ocurren entre enfermedades. Cercospora, la clase minoritaria (22 imágenes de test), es la más difícil (F1 0,53) y se confunde con minador y roya. En hojas con un solo estrés la accuracy es 92 %, pero cae a 66 % en hojas con varios estreses simultáneos, donde la etiqueta «predominante» es ambigua. El resultado es inferior al 95,2 % de Esgario et al. (2020), que usaron ResNet-50 (≈ 6× más parámetros), otra partición y mayor resolución efectiva de la hoja (con nuestro letterbox la hoja ocupa la mitad del lienzo).

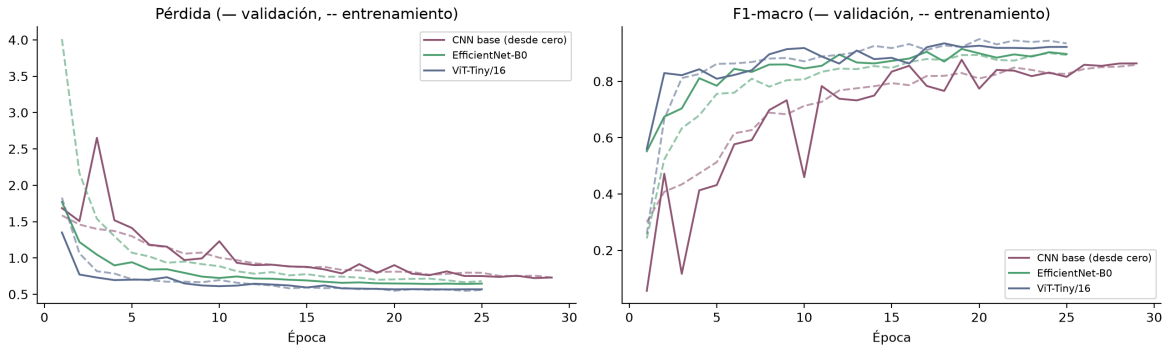


Figura 1. Curvas de pérdida y F1-macro (línea continua: validación; punteada: entrenamiento).

Con aumento de datos no hay sobreajuste: el F1 de entrenamiento (medido con imágenes aumentadas y dropout) queda en o por debajo del de validación, y las curvas aún suben levemente al final (ligero subajuste por el presupuesto de épocas en CPU). ViT converge más rápido (F1 val 0,83 en la época 2); la CNN desde cero es inestable (caídas de la validación hasta 0,46) y el early stopping la detuvo en la época 29. En cambio, la ablación sin aumento sí sobreajusta: F1 train 0,988 vs. val 0,913 y pérdida de validación estancada mientras la de entrenamiento baja. El piso de pérdida (≈ 0,55) se debe al label smoothing.

Dominio (ViT-Tiny)	Acc. 5 clases	Acc. sana/enferma	Recall enferma	Recall sana	AUROC
BRACOL test	87,4 %	100,0 %	100,0 %	100,0 %	1,000
RoCoLe raw	31,3 %	45,4 %	99,5 %	4,2 %	0,753
RoCoLe crop	34,7 %	48,5 %	98,8 %	10,1 %	0,801
RoCoLe mask	69,0 %	85,1 %	90,7 %	80,9 %	0,926

Tabla 2. Generalización: test interno vs. RoCoLe (n = 1393, solo sana/roya). Sana/enferma: puntaje 1 − p(sana).

La generalización se degrada fuertemente: con fotos de campo (raw) la accuracy del modelo seleccionado cae de 87,4 % a 31,3 % porque el 96 % de las hojas sanas se predice como enferma. Recortar la hoja apenas ayuda (34,7 %), pero reemplazar el fondo por blanco (mask) recupera 69,0 % de accuracy y una AUROC sana/enferma de 0,926 (recall sana 81 %, enferma 91 %). El patrón se repite en los tres modelos (AUROC raw 0,57–0,75 → mask 0,90–0,93), lo que indica que la mayor parte de la caída se debe al fondo y la condición de captura; la brecha restante se atribuye a la variedad robusta, la iluminación natural y la cámara. Grad-CAM lo confirma (Figura 2): en raw la activación se reparte entre la hoja y el fondo, y con mask se concentra en la lámina. En BRACOL, la CNN base localiza las lesiones con más precisión que el ViT, cuyos mapas activan a menudo el fondo: una métrica alta no garantiza que el modelo mire la evidencia correcta.

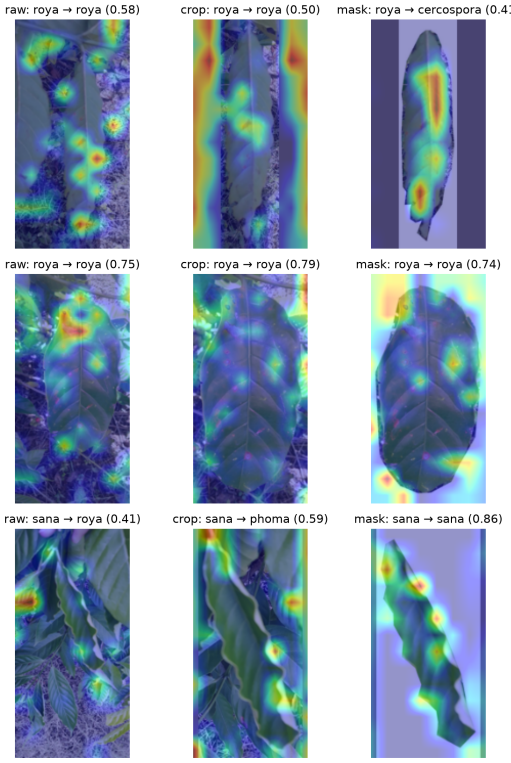


Figura 2. Grad-CAM del mejor modelo en la misma hoja de RoCoLe: raw, crop y mask.

Severidad: con mask, la roya de nivel 1 se detecta en el 84 % de los casos y los niveles 2–4 en ≥ 99 % (falsos positivos en sanas: 19 %). **Clase nunca vista:** la arañita roja se asigna a roya (55 %) o minador (22 %) con la misma confianza que las clases conocidas

(0,54 vs. 0,51; AUROC de detección por confianza máxima = 0,45, equivalente al azar). **Ablación:** sin aumento de datos el F1 en test casi no cambia (85,1 % vs. 86,4 %), pero la AUROC en RoCoLe se desploma (mask 0,59 vs. 0,90; raw 0,43 vs. 0,59): el aumento no mejora el test interno, pero decide la generalización.

5. Conclusiones

Se cumplieron los tres objetivos. (1) El pipeline es reproducible y sin fuga (partición verificada por huella, aumento solo en entrenamiento, test usado una vez, RoCoLe solo para evaluar). (2) El preentrenamiento es decisivo: ViT-Tiny y EfficientNet-B0 logran 87–88 % de accuracy en test frente a 84 % de la CNN desde cero. (3) La generalización a campo se degrada drásticamente (87 % → 31 %), y el experimento raw/crop/mask junto con Grad-CAM muestran que la causa principal es el fondo: el modelo aprendió atajos ligados a la condición de captura de laboratorio. La conclusión central es que un buen resultado en el test interno no implica un modelo útil en campo. **Limitaciones:** una sola partición y semilla (sin intervalos de confianza), etiqueta predominante ambigua en hojas con varios estreses, RoCoLe solo evalúa sana y roya, entrenamiento en CPU con pocas épocas y sin búsqueda de hiperparámetros, y el modelo no detecta clases desconocidas. **Mejoras:** segmentar la hoja antes de clasificar, entrenar con imágenes de campo o aumentos de fondo, formulación multietiqueta, mayor resolución y rechazo de entradas fuera de distribución.

Referencias. *Krohling, Esgario & Ventura (2019) BRACOL, Mendeley Data 10.17632/yy2k5y8mxg.1 · Parraga-Alava et al. (2019) RoCoLe, Data in Brief 25 · Esgario et al. (2020) Comput. Electron. Agric. 169 · Tan & Le (2019) EfficientNet, ICML · Dosovitskiy et al. (2021) ViT, ICLR · Selvaraju et al. (2017) Grad-CAM, ICCV · Hendrycks & Gimpel (2017) ICLR. Código y notebooks: carpeta src/ y notebooks/ del proyecto.*