Clasificación de enfermedades en hojas de café y su generalización a fotos de campo

Cristobal Rodriguez Rojas, Juan Esteban Villada y Cristian David Cabezas Jimenez
Redes Neuronales y Aprendizaje Profundo, Universidad EAFIT, noviembre de 2026

1. Problema y objetivos

La roya del café (*Hemileia vastatrix*) es la enfermedad foliar que más afecta al cultivo y, junto con otras como la cercospora y el minador, reduce la producción. Hoy su diagnóstico depende de que un experto revise las hojas. Las redes convolucionales pueden aprender a reconocer estos síntomas por su textura y color, pero casi todos los datasets públicos se toman en laboratorio, con la hoja sobre un fondo blanco, y no es claro que un modelo entrenado así sirva en campo. **Objetivo general:** desarrollar un modelo de Deep Learning que clasifique enfermedades y plagas en hojas de café y medir qué tan bien generaliza a fotos de otra región, otra variedad y otras condiciones de captura. **Objetivos específicos:** primero, preparar los datos con una partición estratificada y sin fuga de información; segundo, entrenar y comparar una CNN desde cero, EfficientNet-B0 y ViT-Tiny usando accuracy, F1-macro y costo computacional; y tercero, evaluar el mejor modelo en un dataset externo, medir cuánto cae el rendimiento y buscar la causa con Grad-CAM.

2. Datos y preprocesamiento

Para entrenar usamos **BRACOL** (Krohling et al., 2019), con 1747 fotos de hojas de café arábica de Brasil, desprendidas de la planta y fotografiadas sobre fondo blanco. Cada hoja está etiquetada con su estrés predominante. Descartamos las 62 marcadas como indeterminadas y quedaron 1685 hojas en 5 clases: sana 272, minador 387, roya 531, phoma 348, cercospora 147. Las clases están desbalanceadas (roya tiene 3,6 veces más imágenes que cercospora) y el 18,700a0% de las hojas tiene más de una enfermedad. Las dividimos en entrenamiento, validación y prueba (70/15/15, estratificado y con semilla fija), con 1179, 253 y 253 imágenes. Para la evaluación externa usamos **RoCoLe** (Parraga-Alava et al., 2019), que no se usó en ningún momento del entrenamiento: 1560 fotos de café robusta de Ecuador tomadas en campo, con la hoja todavía en la planta. Hay 791 sanas, 602 con roya en niveles de 1 a 4 y 167 con arañita roja, una plaga que no aparece en BRACOL. En el análisis exploratorio ya se notaba la diferencia entre los dos datasets: el brillo medio pasa de 0,62 a 0,41 y el fondo blanco pasa de ocupar el 3000a0% de la imagen a solo el 100a0%. En el preprocesamiento llevamos cada imagen a 256×256 sin deformarla (*letterbox*, rellenando con el color medio de ImageNet), recortamos a 224 píxeles y normalizamos con la media y la desviación de ImageNet. Solo en entrenamiento aplicamos aumento de datos: recortes aleatorios, volteos, rotaciones de 90° y cambios de brillo, contraste y saturación. Además, con las máscaras de segmentación de RoCoLe armamos tres versiones de cada foto externa: la original (*raw*), un recorte a la hoja (*crop*) y la hoja sobre fondo blanco (*mask*). Así podemos ver cuánto influye el fondo.

3. Modelos y entrenamiento

Comparamos tres modelos. El primero es una **CNN** que diseñamos y entrenamos desde cero, con 4 bloques convolucionales (cada uno con dos convoluciones 3×3 con batch normalization y ReLU, y un max pooling), global average pooling y una capa final; tiene 1,17 M de parámetros. El segundo es **EfficientNet-B0** (Tan y Le, 2019), formada por 16 bloques MBConv que usan convoluciones *depthwise* y *squeeze-and-excitation*, con 4,01 M de parámetros. El tercero es **ViT-Tiny/16** (Dosovitskiy et al., 2021), un transformer que divide la imagen en 196 parches y los procesa con 12 bloques de *self-attention*, con 5,53 M de parámetros. Los dos últimos parten de pesos preentrenados en ImageNet; lo único que les cambiamos fue la capa de salida, que ahora tiene 5 clases y dropout, y ajustamos toda la red. Entrenamos con AdamW, con learning rate de 1e-3 para la CNN, 3e-4 para EfficientNet y 1e-4 para el ViT, 2 épocas de *warmup* y luego decaimiento coseno, y batch de 32. Como pérdida usamos entropía cruzada con pesos inversos a la frecuencia de cada clase y *label smoothing* de 0,1. Nos quedamos con la época de mejor F1-macro en validación, con *early stopping* y un máximo de 40 épocas para la CNN y 25 para los demás. También entrenamos una EfficientNet-B0 solo con volteos, para medir el efecto del aumento de datos. Todo se entrenó en un portátil con CPU Intel Core i5-1155G7, sin GPU, 20 GB de RAM y PyTorch 2.15 con timm.

4. Resultados

Modelo	Accuracy	F1-macro	Mejor ép.	Parám.	Entrenam.	ms/img CPU
CNN base (desde cero)	84,2 %	80,8 %	19/29	1,17 M	105 min	67
EfficientNet-B0	88,1 %	86,4 %	19/25	4,01 M	89 min	53
ViT-Tiny/16	87,4 %	84,3 %	18/25	5,53 M	53 min	45
EfficientNet-B0 sin aumento	88,1 %	85,1 %	22/25	4,01 M	76 min	41

Tabla 1. Resultados en la partición de prueba de BRACOL (253 imágenes). Esgario et al. (2020) reportan 95,2400a0% de accuracy en este dataset con otra partición.

Los dos modelos preentrenados llegan a 87–8800a0% de accuracy en prueba y superan a la CNN desde cero por entre 3,4 y 5,5 puntos de F1-macro. Elegimos ViT-Tiny porque tuvo el mejor F1 en validación (0,935). En prueba EfficientNet-B0 queda uno o dos puntos por encima, pero sobre 253 imágenes eso equivale a entre 3 y 5 aciertos, así que no lo tomamos como una diferencia real. Separar hojas sanas de enfermas no fue problema en este dataset (AUROC de 1,0): todos los errores son confusiones entre enfermedades. La clase más difícil fue cercospora, con F1 de 0,53; es la que menos imágenes tiene y se confunde con minador y roya. En las hojas con una sola enfermedad el modelo acierta el 9200a0%, pero en las que tienen varias baja al 6600a0%, porque ahí

no es tan claro cuál es la enfermedad predominante. Nuestro resultado queda por debajo del 95,200a0% de Esgario et al. (2020), aunque ellos usaron una ResNet-50, unas seis veces más grande, otra partición y la hoja a mayor resolución.

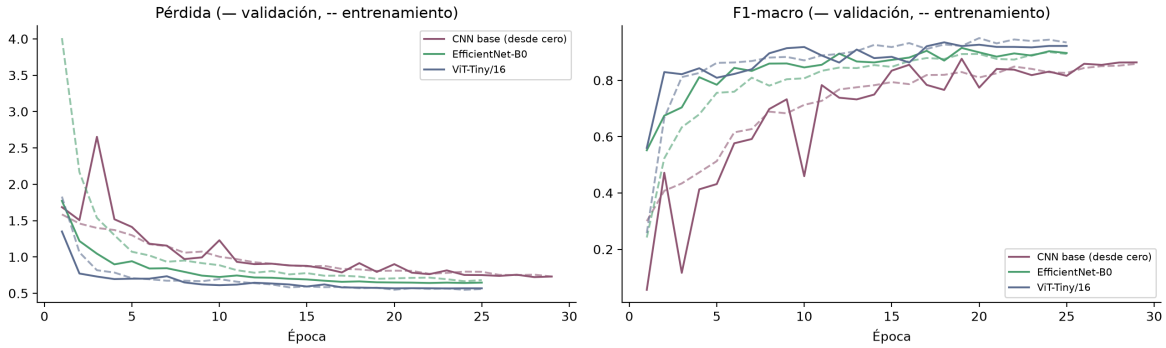


Figura 1. Curvas de pérdida y F1-macro. La línea continua es validación y la punteada, entrenamiento.

En los modelos entrenados con aumento de datos no vemos sobreajuste. El F1 de entrenamiento queda igual o por debajo del de validación, porque se calcula sobre imágenes aumentadas y con dropout activo. Las curvas todavía suben un poco al final, así que con más épocas probablemente se ganaría algo más. El ViT converge más rápido (en la segunda época ya tiene F1 de 0,83 en validación), mientras que la CNN desde cero es bastante inestable, con caídas de la validación hasta 0,46, y el early stopping la detuvo en la época 29. El modelo sin aumento de datos sí sobreajusta: llega a un F1 de 0,988 en entrenamiento contra 0,913 en validación. La pérdida no baja de 0,55 por el label smoothing.

Dominio (ViT-Tiny)	Acc. 5 clases	Acc. sana/enferma	Recall enferma	Recall sana	AUROC
BRACOL test	87,4 %	100,0 %	100,0 %	100,0 %	1,000
RoCoLe raw	31,3 %	45,4 %	99,5 %	4,2 %	0,753
RoCoLe crop	34,7 %	48,5 %	98,8 %	10,1 %	0,801
RoCoLe mask	69,0 %	85,1 %	90,7 %	80,9 %	0,926

Tabla 2. Resultados del ViT-Tiny en la prueba interna y en RoCoLe (1393 fotos sanas o con roya). Para sana contra enferma usamos 1 – p(sana) como puntaje.

Con las fotos de campo los resultados empeoran mucho. La accuracy del ViT pasa de 87,400a0% en la prueba interna a 31,300a0% en RoCoLe, sobre todo porque el 9600a0% de las hojas sanas se clasifica como enferma. Recortar la hoja casi no cambia nada (34,700a0%), pero cuando ponemos la hoja sobre fondo blanco la accuracy sube a 69,000a0% y la AUROC entre sana y enferma llega a 0,926. Con los otros modelos pasa lo mismo: la AUROC está entre 0,57 y 0,75 con las fotos originales y entre 0,90 y 0,93 con fondo blanco. Por eso creemos que la mayor parte de la caída viene del fondo y de las condiciones de la foto, y que lo que no se recupera se debe a diferencias como la variedad robusta, la luz natural y la cámara. Los mapas de Grad-CAM van en la misma línea (Figura 2): con la foto original el modelo se fija tanto en la hoja como en el fondo, y con fondo blanco se concentra en la hoja. En BRACOL, en cambio, la CNN desde cero marca las lesiones mejor que el ViT, que muchas veces se activa en el fondo, de modo que el modelo con mejor métrica no siempre es el que mira las zonas correctas.

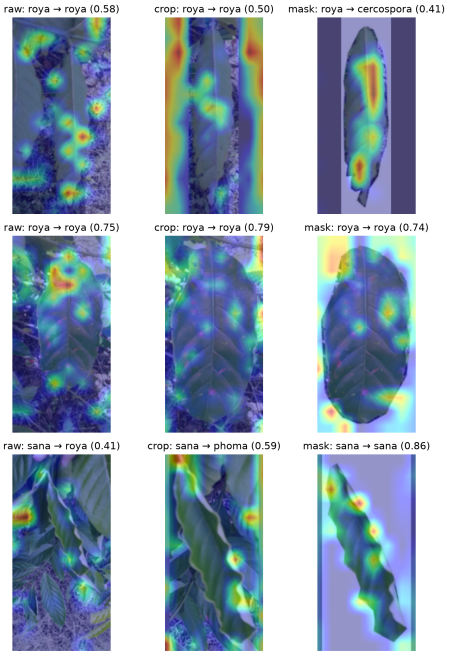


Figura 2. Grad-CAM del ViT-Tiny sobre tres hojas de RoCoLe (una por fila), cada una en sus versiones raw, crop y mask.

En cuanto a la severidad, con fondo blanco el modelo detecta el 8400a0% de la roya de nivel 1 y casi toda la de niveles 2 a 4, aunque marca como enfermas el 1900a0% de las hojas sanas. La arañita roja, que el modelo nunca vio, la clasifica casi siempre como roya (5500a0%) o minador (2200a0%), con una confianza parecida a la de las clases conocidas (0,54 frente a 0,51). Por eso la confianza no sirve para detectarla: la AUROC es de 0,45, que es como adivinar. Por último, en la ablación, quitar el aumento de datos casi no afecta el F1 en prueba (85,100a0% contra 86,400a0%), pero en RoCoLe con fondo blanco la AUROC cae de 0,90 a 0,59. O sea que el efecto del aumento de datos no se ve en la prueba interna, pero sí cuando cambian las condiciones de las fotos.

5. Conclusiones

Cumplimos los tres objetivos. Armamos un proceso reproducible en el que la partición de prueba se usó una sola vez y RoCoLe solo se usó para evaluar. Los modelos preentrenados funcionaron mejor que la CNN desde cero (87–8800a0% frente a 8400a0% de accuracy). Y comprobamos que en campo el rendimiento cae de 8700a0% a 3100a0%; con las tres versiones de RoCoLe y con Grad-CAM vimos que la causa principal es el fondo, es decir, que el modelo aprendió cosas propias de las fotos de laboratorio. En resumen, un buen resultado en la prueba interna no basta para saber si el modelo va a funcionar en campo. El trabajo tiene varias limitaciones: usamos una sola partición y una sola semilla, por lo que no tenemos intervalos de confianza; la etiqueta de las hojas con varias enfermedades es ambigua; RoCoLe solo permite evaluar sana y roya; entrenamos en CPU con pocas épocas y sin buscar hiperparámetros; y el modelo no reconoce las clases que no conoce. Como trabajo futuro proponemos segmentar la hoja antes de clasificarla, entrenar con fotos de campo o con fondos variados, tratar el problema como multietiqueta, usar mayor resolución y agregar una forma de rechazar imágenes desconocidas.

Referencias. *Krohling, Esgario y Ventura (2019), BRACOL, Mendeley Data, doi:10.17632/yy2k5y8mxg.1. Parraga-Alava et al. (2019), RoCoLe, Data in Brief 25. Esgario et al. (2020), Computers and Electronics in Agriculture 169. Tan y Le (2019), EfficientNet, ICML. Dosovitskiy et al. (2021), ViT, ICLR. Selvaraju et al. (2017), Grad-CAM, ICCV. Hendrycks y Gimpel (2017), ICLR.*